

A-1100 Wien, Favoritenstr. 226
Tel.: 01/606 68 77 DW 2130, Fax: 01/606 68 77 DW 2139
its@fh-campuswien.ac.at

DISPOSITION

Fahreridentifikation mittels Machine-Learning Driver identification by Machine-Learning

Student:

David Lechner
1810537012

Betreuer:

Dr. Martin Schmiedecker
Kevin Koch

Freigabe durch Unterschrift des Erstbetreuers:

Wien, am 14.10.2019

Inhaltsverzeichnis

1. Einleitung
2. Beschreibung, Überblick, Ziele
3. Kontext
4. Neuigkeitswert der Arbeit
5. Rahmenbedingungen
6. Zeitplan
7. Literaturverzeichnis

1. EINLEITUNG

Der Präfix Smart ist in der heutigen Alltagssprache täglich in Verwendung. Entweder wird es in Verbindung mit einem Telekommunikationsgerät oder mit anderen sogenannten *Wearables* gebracht. Damit ist gemeint, dass diese mit Funktechnologien ausgestattet sind und Daten übermitteln. Der Bereich *Internet of Things* (IoT) ist noch einmal eine Weiterentwicklung, bei dem jegliches technische Gerät – von der Lampe bis hin zur Fertigungsmaschinen – mit dem Internet verbunden ist. Dieser Trend macht auch vor Fahrzeugen keinen Halt. Schon längst sind moderne Autos mit LTE-, GPS und Wifi-Modulen ausgestattet und senden Daten unter anderem zum Hersteller. Gartner prognostiziert für das Jahr 2020 470 Millionen vernetzte Fahrzeuge [2]. In Zukunft werden wahrscheinlich alle Fahrzeuge mit etlichen Sensoren ausgestattet sein und kommunizieren untereinander, mit der Umwelt, dem Fahrer oder sonstige Service-Anbieter. Dies gründet vor allem auf den wachsenden Themen *Vehicle-to-Everything* (V2X) und autonomes Fahren. Insbesondere beim letztgenannten wird zudem eine riesige Menge an Daten aus tausenden Sensoren gewonnen. Schon heute senden *Electronic Control Units* (ECUs) Daten, wie zum Beispiel Lenkradwinkel, Gangposition und Bremsdruck, welche für Sicherheits- und Komfortfunktionen genutzt werden. Durch diese Vielzahl an verschiedenen Daten ergeben sich viele weitere Möglichkeiten. Eine davon ist, den Lenker eines Autos während der Fahrt nur durch das Fahrverhalten zu identifizieren.

Daraus lassen sich unterschiedliche Anwendungen ableiten. Einige von ihnen schaffen Komfort und erleichtern in gewisser Weise das Leben des Fahrers. Andere indes könnten gegen den Fahrzeughalter und der Fahrerin selbst eingesetzt werden, diese gehen mit datenschutzrechtlichen Bedenken einher.

Doch zunächst zu diesen, welche eine positive Auswirkung haben können. Moderne Autos – vor allem jene mit einem Automatik Getriebe – bieten die Möglichkeit sich an den Fahrstil anzupassen. Wenn beispielsweise eine Person zum schnelleren Beschleunigen neigt, lernt dies das Auto und schaltet demnach erst bei einer höheren Motordrehzahl in den nächsthöheren Gang. Dasselbe gilt bei einem gemächlichen Fahrstil, wobei hier eher früher geschaltet wird. Lernt das Auto nun von einer Person mit dem zweitgenannten Stil und wird aber auch hin und wieder mit anderen Personen, zum Beispiel Familienmitglieder, geteilt, kann es für diese ein Komfortverlust darstellen. Identifiziert das Auto jedoch durch das Fahrverhalten eine andere Person, könnte es den gelernten Stil temporär vergessen oder gar ein neues Profil anlegen und erneut lernen.

Der Mechanismus kann weiters dazu verwendet werden, Fahrzeug-Funktionen und Leistung fahrerabhängig zu steuern. Ein Familienvater ist so etwa in der Lage, die zur Verfügung stehenden PS einzuschränken, wenn seine Kinder mit dem Auto fahren.

Überdies ist eine Art Diebstahlwarnung zu realisieren. Wird eine unautorisierte Fahrerin eines Autos erkannt, kann beispielsweise eine Benachrichtigung an den Fahrzeughalter versendet, oder die Fahrerin zum Anhalten gebracht werden.

Durch das Aufzeichnen und Analysieren von personenbezogenen Daten kommen natürlich auch datenschutzrechtliche Bedenken auf. Werden die Daten in eine Cloud – sei es eine vom Hersteller, Versicherung oder einer anderer Drittpartei – gesendet und ausgewertet, können Personen von diesen Unternehmen oder Organisationen eindeutig identifiziert und geortet werden. Dies kann in einigen Fällen problematisch werden. Des Weiteren könnte der Hersteller bestimmte Services anbieten, welche personalisierte Werbungen während dem Fahren anzeigen. Eventuell ist es dadurch möglich, bevorzugte Restaurants in der Navigationsansicht hervorzuheben.

Die Angeführten Beispiele zeigen, dass ein System, welches die Person hinter dem Lenkrad eines Fahrzeuges eindeutig identifiziert, Benutzervorteile bringen kann. Zudem erschließt sich ein neues Geschäftsfeld für Autohersteller, um vielleicht Premium-Features anbieten zu können. Jedoch stellen sich auch Fragen zur Privatsphäre und wie mit solch sensiblen Daten umgegangen wird.

2. BESCHREIBUNG, ÜBERBLICK, ZIELE

In der Masterarbeit soll ein System entwickelt werden, welches einen Fahrer anhand von Fahrzeugdaten eindeutig identifizieren kann. Bei diesen Daten handelt es sich um Controller-Area-Network (CAN) Nachrichten, die zwischen Electronic-Control-Units (ECUs) ausgetauscht werden. Typische Nachrichten sind Lenkradwinkel, Motordrehzahl, Bremsdruck und Blinker Ein/Aus.

Aktuelle Forschungen (siehe Kapitel 4) zeigen, dass mehrere Personen aufgrund des Fahrstils eindeutig voneinander unterscheidbar und zuordenbar sind. Hierbei wird eine Untermenge von *Artificial Intelligence* (AI), nämlich *Machine-Learning* (ML) eingesetzt. Bei ML handelt es sich um mehrere mathematischen Algorithmen, welche statistische Modelle aufgrund von Trainingsdaten aufbauen. Die Modelle versuchen in Folge dessen einen Zusammenhang oder Muster in den Daten zu erkennen. Solche Lerndaten bestehen aus verschiedenen Datenpunkten und einem Zielwert. Nach der Trainingsphase eines Modells können Testdaten ohne diesen Zielwert eingespielt werden. Als Resultat wird ein Zielwert mit einer gewissen Wahrscheinlichkeit ausgegeben [5]. In diesem Zusammenhang bestehen die Trainingsdaten aus den verschiedenen CAN-Nachrichten und der Fahreridentifikation (Zielwert). In der Testphase werden nur noch die CAN-Nachrichten verwendet und das Modell liefert eine passende Fahrer-ID.

Für die statistischen Modelle gibt es mehrere Algorithmen, zum Beispiel *k-nearest-neighbor* (KNN), *Random-Forrest* oder *Linear Regression*, welche unterschiedlich genaue Resultate liefern. Diese Masterarbeit soll deshalb auch aufzeigen, welche Algorithmen mit welchen Parametern sich am Besten für diesen Gebrauch eignen.

Für jegliche *Machine-Learning* Anwendung sind die Daten an sich ausschlaggebend. Wenn beispielsweise zu wenig Daten für das Trainieren vorhanden, zu ungenau oder nicht authentisch beziehungsweise gar nicht klassifiziert sind, kann das beste Modell keine korrekten und genauen Ergebnisse liefern. Unter der Klassifizierung versteht man bei ML das Kennzeichnen von Datenpunkten, also in diesem Fall die Zuordnung zu einem Fahrer. Für die Masterarbeit liegen sehr viele CAN-Nachrichten mit einer eindeutigen Fahrerzuordnung auf (für mehr Informationen zur Herkunft siehe Kapitel 5). Eine CAN-Nachricht besteht aus mehreren CAN-Signalen, welche von einem Steuergerät aus gesendet werden. Die folgende Tabelle listet die voraussichtlich interessantesten Signale für diese Aufgabe. Ein weiterer Teil der Arbeit wird sich damit beschäftigen, die vielversprechendsten Signale herauszufiltern.

Tabelle 1: Signalbeschreibung

Signalname	Kurzbeschreibung	Einheit	Wertbeschreibung
LWI_Lenkradwinkel	Lenkradwinkel	Grad	
LWI_VZ_Lenkradwinkel	Vorzeichen von Lenkradwinkel	Boolean	0: positiv 1: negativ
ESP_Fahrer_bremst	Bremspedal betätigt	Boolean	0: nicht betätigt 1: betätigt
ESP_Bremsdruck	Bremsdruck	Bar	
MO_Fahrpedalrohwert	Fahrpedalrohwert		
MO_Kuppl_schalter	Kupplung betätigt	Boolean	0: nicht betätigt 1: betätigt
MO_Drehzahl	Motordrehzahl	rpm	
MO_Gangposition	Gangposition	Integer	1: Gang 1 oder rückwärts 2-6: Gang 2-6
ESP_V_Signal	Fahrzeuggeschwindigkeit	Km/h	
ESP_HL_Fahrtrichtung	Fahrtrichtung Rad links hinten	Integer	0: Vorwärts 1: Rückwärts
ESP_HR_Fahrtrichtung	Fahrtrichtung Rad rechts hinten	Integer	2: Initialisierung 3: Nicht valide

Jede Nachricht beinhaltet nicht nur die Signale und deren Werte, sondern auch einen Zeitstempel des Empfangszeitpunktes. Dieser ist in Nanosekunden aufgelöst. Für ML ist es essentiell, dass die Eingabedaten so strukturiert wie möglich sind, dies beinhaltet auch die Häufigkeit der Nachrichten. Berechnet man die Frequenz der verschiedenen Signale und stellt diese dar (siehe Abbildung 1), erkennt man, dass alle Signale einer Nachricht die gleiche Häufigkeit aufweisen. Jedoch gibt es Unterschiede zwischen den Steuergeräten. Zum Beispiel sendet das Lenkrad- und Motorsteuergerät mit der gleichen Frequenz – nämlich 100-mal in der Sekunde. Andere jedoch, wie das Getriebesteuergerät, nur mit einer Frequenz von 10Hz. Es gilt daher auch herauszufinden, ob es notwendig ist, die Nachrichtenhäufigkeit durch beispielsweise lineare Interpolation oder durch das Berechnen eines Durchschnitts anzugleichen. Neben der Häufigkeitsanpassung

müssen noch viele weitere Überlegungen angestellt werden, um die Daten bestmöglich für ML zu präparieren. In diesem Kontext wird darunter *Feature-Extraction* und *Pre-Processing* verstanden.




Abbildung 1: Signalfrequenz

Das nächste Ziel dieser Masterarbeit ist, dass System zur Fahreridentifizierung, sofern es überhaupt möglich ist, in ein Fahrzeug zu integrieren. Ein eigener Boardcomputer (siehe Kapitel 5) soll in (fast)-Echtzeit CAN-Nachrichten mitlesen, analysieren und anhand von zuvor erstellten Modellen den Fahrer identifizieren. Bei dieser Aufgabenstellung ist es vor allem interessant zu wissen, ob und wie ein Embedded-Device eine solch intensive Rechenaufgabe bewerkstelligen kann. Der Ablauf dabei ist wie folgt vorgesehen: Dem Boardcomputer wird mitgeteilt, dass sich ein neuer Lenker hinter dem Steuer befindet und in den Lernmodus schalten soll. Für eine gewisse Zeit wird das Fahrverhalten eingelernt und ein Profil erstellt. Wenn dieses Profil mit einer hohen Wahrscheinlichkeit die dazugehörige Fahrerin identifizieren kann, wird es abgelegt und gespeichert. Dieser Vorgang soll mit mehreren Lenkern durchgeführt werden. Abschließend wird der Boardcomputer in den Normal-Betrieb geschaltet. Dort wird festgestellt, ob sich der derzeitige Fahrer in den bereits gelernten Profilen befindet oder nicht. Zusätzlich soll herausgefunden werden, wie lange eine Lernphase dauern muss, um eine hohe Trefferquote (> 85%) erzielen zu können. Des Weiteren ist es relevant zu wissen, aus wie vielen Profilen noch eine akkurate Entscheidung getroffen werden kann.

Die folgende Liste fasst die Ziele der Masterarbeit noch einmal zusammen.

1. Die Masterarbeit behandelt die Fahreridentifikation basierend auf CAN-Nachrichten mittels *Machine-Learning*.
2. Es sollen performante ML Algorithmen und Parameter für eine schnelle Identifikation ermittelt werden.
3. Das System soll auf einem Embedded-Device mit beschränkten Ressourcen implementiert und in ein Fahrzeug integriert werden.

4. Es soll die Anzahl an unterschiedlichen Fahrerprofilen bestimmt werden, aus denen zu einer Wahrscheinlichkeit von mindestens 85% noch unterschieden werden kann.

Die Ziele der Masterarbeit sind jedoch nicht

- einen Lenker zu 100% aus mehreren Fahrprofilen unterscheiden zu können.
- das System mit verschiedenen Fahrzeugtypen zu testen.
- Applikationen basierend auf dem System zu entwickeln.

3. KONTEXT

Der praktische Teil der Masterarbeit wird im Unternehmen – Bosch Engineering – implementiert. Als Dienstleister für Kunden innerhalb und außerhalb von Bosch ist es wichtig, Kompetenzen in neuen technischen Bereichen aufzubauen. Zudem sollen stets neue Services entwickelt und bestehende Produkte verbessert werden, um am Markt konkurrenzfähig bleiben zu können. Die Fahreridentifikation basierend auf CAN-Daten mittels *Machine-Learning* kann einerseits ein neues *Feature* für das Produkt *ALEN* (siehe Kapitel 5.3) sein und andererseits als Kompetenzaufbau gesehen werden.

4. NEUIGKEITSWERT

In diesem Kapitel werden die aktuellsten Arbeiten zu diesem Thema kurz vorgestellt und der Neuigkeitswert von der Masterarbeit klar aufgezeigt.

In einem Paper von 2016 wurde untersucht, ob Einzelpersonen basierend auf ihren natürlichen Fahrverhalten identifiziert werden können. Für die Datenbasis wurden CAN-Nachrichten eines Serienfahrzeuges verwendet. 15 Teilnehmer mussten zuerst bestimmte Manöver auf einem abgesperrten Parkplatz durchführen und danach eine ca. 80 km lange vordefinierte Strecke abfahren. Für die Analyse wurde *Machine-Learning* mit verschiedenen Algorithmen verwendet. Dabei konnte festgestellt werden, dass bei einem 1 zu 1 Vergleich die Teilnehmer zu 100% unterscheidbar sind. Des Weiteren konnte eine hohe Identifikationswahrscheinlichkeit bei nur acht Minuten Trainingszeit erzielt werden [4].

Die Arbeit von B. Gahr et. al. von 2018 setzt auf die soeben beschriebenen auf. Da gezeigt wurde, dass eine Identifikation zu 100% möglich ist, hat diese es versucht mit anderen Daten zu validieren. Dafür wurden aber nicht direkt die Nachrichten vom CAN-Bus abgegriffen, sondern über ein Smartphone, welches über Bluetooth mit einem OBDII-Dongle verbunden wurde. Hierbei konnte mit den Methoden jedoch nur eine Identifikationsrate von maximal 70% erzielt werden. Daher wurde ein anderer Ansatz gewählt, bei dem nur Daten während eines Bremsvorgangs in Betracht gezogen werden. Das hat zu Ergebnissen zwischen 80 und 99,5% geführt [3].

Ein anderes Paper verfolgte einen ähnlichen Ansatz, bei dem nur die Daten während einer Kurve berücksichtigt werden. Die CAN-Nachrichten wurden hierbei mit einem proprietären Data-Logger aufgezeichnet. Es folgte eine Analyse der 12 häufigsten Kurven im Datensatz. Dabei konnte ein Fahrer verglichen mit einem zweiten Fahrer mit einer Wahrscheinlichkeit von fast 77% unterschieden werden. Besteht das Set aus fünf Fahrern, war die Identifikationsrate bei 50,1% [1].

Die Masterarbeit wird teilweise auf die bereits bestehenden Papers aufsetzen und bewährte Methoden übernehmen. Ein wesentlicher Unterschied ist aber, dass die hier vorliegenden Daten (siehe unten) weder in einem bestimmten Setting noch unter anderen Kontrolleinflüssen und direkt vom CAN-Bus mitgemessen worden sind. Wie auch aus den Zielen hervorgeht, wird versucht, die Methoden dahingehend zu verbessern, sodass eine möglichst schnelle Identifikation durchgeführt werden kann.

Wenn das entwickelte System zur Fahreridentifizierung mit den Daten erfolgreich und performant ist, soll es in ein Fahrzeug integriert und mit neuen Live-Daten getestet werden.

5. RAHMENBEDINGUNGEN

Um diese Masterarbeit durchführen zu können, sind viele Datensätze, Rechenleistung und ein Embedded-Device notwendig.

5.1 CAN-Nachrichten

Wie bereits in Kapitel 2 beschrieben, sind Datensätze für jegliche *Machine-Learning* Anwendung entscheidend. Nicht nur, dass viele vorhanden, sondern auch korrekt klassifiziert sind. Die vorliegenden Daten für die Arbeit erfüllen beide Kriterien. Sie wurden von einem Boardcomputer aufgezeichnet, welcher im Fahrzeug (VW Golf 7, keine näheren Informationen) verbaut ist. Eine Datei beinhaltet 46 verschiedene Signale und durchschnittlich 10000 Datenpunkte über eine Dauer von einer Minute, die auf dem CAN-Bus gesendet wurden. Bevor die Binärdatei über eine LTE-Funkverbindung auf einen Server hochgeladen wurde, ist eine eindeutige Fahrzeugidentifikation und ein synchronisierter Zeitstempel an den Dateinamen angefügt worden. Insgesamt sind Daten von zehn verschiedenen Fahrzeugen über einen Zeitraum von zwei Wochen vorhanden. Dabei ist garantiert, dass jeweils nur eine Person mit einem Fahrzeug gefahren ist. Die Fahrten selbst sind von Fahrer zu Fahrer sehr unterschiedlich und individuell – sowohl von der Fahrzeit, Route und Ort als auch Start-/Endzeitpunkt einer Fahrt. Daraus resultiert eine gesamte Rohdatenmenge von 4,2GB. Für eine bessere Weiterverarbeitung wurden die Binärdaten in das CSV-Format umgewandelt. Da dieses ASCII basiert ist, hat sich die Größe auf 12GB erhöht. Ebenso muss festgehalten werden, dass die Dateien von personenbezogenen Daten aufgrund von Datenschutzgründen bereinigt wurden. Es finden sich somit keine GPS Daten darunter. Bei der Konvertierung sind alle Signale einer Nachricht in eine eigene

CSV-Datei geschrieben worden. Abbildung 2 zeigt einen Auszug einer solchen Datei mit Lenkraddaten.

```
Data > 1565710781118468915_8c52290b-423f-4722-bf9b-1742e064bbfa.ChannelGroup_13_LWI_01:.csv
1 time,can0_LWI_Lenkradwinkel,can0_LWI_VZ_Lenkradwinkel,can0_LWI_VZ_Lenkradw_Geschw,can0_LWI_Lenkradw_Geschw
2 0.0,8.700000000000001,1,0,0.0
3 0.009940862655639648,8.8,1,1,0.0
4 0.01989293098449707,9.0,1,1,0.0
5 0.029851198196411133,9.3,1,1,0.0
6 0.039788007736206055,9.700000000000001,1,1,40.0
7 0.04959297180175781,10.200000000000001,1,1,55.0
8 0.059680938720703125,10.8,1,1,65.0
9 0.06962990760803223,11.5,1,1,75.0
10 0.07957696914672852,12.4,1,1,85.0
11 0.0894770622253418,13.3,1,1,95.0
12 0.09947896003723145,14.4,1,1,105.0
13 0.1094210147857666,15.5,1,1,110.0
14 0.11936783790588379,16.7,1,1,120.0
15 0.12931299209594727,18.0,1,1,125.0
16 0.13927197456359863,19.3,1,1,130.0
17 0.14921212196350098,20.6,1,1,135.0
18 0.15917110443115234,22.0,1,1,135.0
19 0.169111967086792,23.3,1,1,135.0
20 0.1790599822998047,24.700000000000003,1,1,135.0
21 0.18894410133361816,26.0,1,1,135.0
22 0.19894814491271973,27.400000000000002,1,1,135.0
23 0.20889711380004883,28.8,1,1,140.0
24 0.21884489059448242,30.200000000000003,1,1,140.0
25 0.22879624366760254,31.6,1,1,140.0
26 0.2387399673461914,33.0,1,1,140.0
27 0.24855399131774902,34.4,1,1,135.0
```

Abbildung 2: CSV Ausschnitt

5.2 Rechenleistung

Machine-Learning erfordert einen hohen Rechenaufwand mit vielen kleineren Berechnungen. Aufgrund dieser Anforderung eignen sich vor allem Graphikkarten (GPUs) für diesen Einsatz. Diese beinhalten im Gegensatz zu normalen Central-Processing-Units (CPUs) sehr viele logische Prozessoren, die parallel Berechnung durchführen. Je nach ML-Algorithmus und Größe der Trainingsdaten kann die Erstellung eines Modells von ein paar Minuten bis hin zu einer Woche dauern. Deshalb sind entsprechende Ressourcen unerlässlich, um nicht zu lange auf Ergebnisse warten zu müssen. Hierfür gibt es drei Optionen. Es könnte zum Beispiel selbst die notwendige Hardware angeschafft werden, um die Rechenleistung zu bekommen, dies erfordert jedoch einen hohen Zeit- und Geldaufwand. Die zweite Möglichkeit ist, die bestehende Infrastruktur von Bosch zu verwenden. Das hat aber den Nachteil, dass diese nicht immer zu jeder Zeit zur Verfügung steht. Die letzte Option wäre, Dienste von Amazon oder Google zu nutzen. Diese Konzerne bieten eigens für *Machine-Learning* entwickelte Plattformen an. Die Kosten dürften sich hier im überschaubaren Rahmen befinden, welche von einem Studentenkonto gedeckt werden.

5.3 Embedded-Device

Um das System zur Fahreridentifizierung in ein Auto integrieren zu können, wird ein Embedded-Device benötigt. Dieses muss für den Einsatz im Automotiv-Umfeld

konzipiert sein und eine CAN-Schnittstelle sowie ein robustes Gehäuse haben. Bosch bietet eine Reihe solcher Geräte an, doch das vielversprechendste ist die sogenannte *Automotive-Linux-Edge-Node Box*, oder kurz *ALEN*. Ursprünglich wird das Gerät beim israelischen Unternehmen *CompuLab* hergestellt und von Bosch an Automotive-Bedingungen angepasst. Abbildung 3 zeigt es. Der Einsatzbereich liegt dort, wo Daten vom Fahrzeug an eine Cloud gesendet werden.



Abbildung 3: ALEN (Quelle: <https://www.compulab.com>)

Wie in den Zielen definiert, ist der Plan, die ALEN in ein Fahrzeug zu verbauen und die Fahreridentifikation mit Live-Daten zu testen. Zum jetzigen Zeitpunkt sind jedoch noch keine Informationen über das Testfahrzeug, welches von Bosch bereitgestellt wird, vorhanden.

6. ZEITPLAN

Folgende Tabelle zeigt den Zeitplan für die Masterarbeit.

Tabelle 2: Zeitplan

#	Beschreibung	Datum
1	Abgabe Disposition	27.10.2019
2	Beginn Masterarbeit	28.10.2019
3	Data preprocessing	03.11.2019
4	Inhaltsverzeichnis	10.11.2019
5	Kapitel <i>Machine-Learning</i>	17.11.2019
6	Erste ML Modelle implementiert	01.12.2019
7	Erfolgreiche Fahreridentifikation	29.12.2019
8	Identifikationsoptimierung	19.01.2020
9	Integrierung auf Embedded-Device	09.02.2020
10	Testfahrten abgeschlossen	23.02.2020
11	Masterarbeit fertiggestellt	01.05.2020

7. LITERATURVERZEICHNIS

- [1] D. Hallac, A. Sharang, R. Stahlmann, A. Lamprecht, M. Huber, M. Roehder, R. Sasic und J. Leskovec, „Driver identification using automobile sensor data from a single turn,“ in *2016 IEEE 19th International Conference on Intelligent Transportation Systems (ITSC)*, 2016.
- [2] I. Gartner, „Gartner Says 5.8 Billion Enterprise and Automotive IoT Endpoints Will Be in Use in 2020,“ 2019.
- [3] B. Gahr, B. Ryder, A. Dahlinger und F. Wortmann, „Driver Identification via Brake Pedal Signals — A Replication and Advancement of Existing Techniques,“ in *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, 2018.
- [4] M. Enev, A. Takakuwa, K. Koscher und T. Kohno, „Automobile Driver Fingerprinting,“ *Proceedings on Privacy Enhancing Technologies*, Bd. 2016, pp. 34-50, 1 2016.
- [5] D. Conway, *Machine Learning for Hackers*, O'Reilly Media, Inc, USA, 2012.